Literatür Taraması

Diyabet tahmini üzerine yapılan altı çalışma incelenmiş ve hangi algoritmaların hangi koşullarda daha başarılı olduğu araştırılmıştır. Genel tabloda, Random Forest, XGBoost ve AdaBoost gibi topluluk (ensemble) yöntemleri çoğu çalışmada en iyi sonucu vermiş; derin öğrenme ise her çalışmada üstün çıkmamıştır. Mobil uygulama çalışmasında on sınıflandırma algoritması, Pima veri seti ve 300 gönüllüden oluşan özel bir veri seti ile karşılaştırılmıştır. SMOTE ile dengelenmiş XGBoost, özel veri setinde %97,4 doğruluk, 0,95 F1 ve 0,87 AUC elde etmiş ve model bir mobil uygulamaya taşınmıştır [1]. Bu sonuç 300 örneklik bir veriden geldiği için dikkatle yorumlanmalıdır; iki veri seti birleştirildiğinde doğruluk %83,1'e düşmektedir. Kendini açıklayan arayüz çalışmasında Decision Tree, KNN, SVC ve XGBoost karşılaştırılmış; XGBoost diğerlerinden hafifçe daha iyi performans göstermiştir [2]. SHAP ile her tahmin için yerel açıklamalar üretilip bir arayüze eklenmiştir. Bu yaklaşım, yalnızca tahmin üretmek yerine tahminin hangi değişkenlerden kaynaklandığını göstermek için projemize faydalı bir örnektir. Ancak model herkese açık bir veri setinde test edilmiştir ve klinik kullanımdan önce daha kapsamlı veriyle doğrulanması gerekir. Pediatrik çalışmada tek bir çocuk hastanesinden alınan 548 hastanın 18 özelliği kullanılmış ve on gizli katmanlı bir MLP modeli ile %99,8 doğruluk bildirilmiştir [3]. Bu sonuç derin öğrenmenin diyabet tahmininde değerlendirilebileceğini gösterir ve klasik modellerin yanında MLP'nin denenmesi için bir gerekçe sunar. Ancak örneklem küçük ve tek merkezlidir; bu kadar yüksek bir doğruluk farklı yaş gruplarında veya merkezlerde aynı şekilde korunmayabilir. Yeniden yatış çalışmasında 1999–2008 yıllarına ait, 130 ABD hastanesinden alınan 101.766 kayıt kullanılmış ve on klasik model ile bir LSTM, 30 gün içinde yeniden yatışı tahmin etmek için karşılaştırılmıştır [4]. Öznitelik seçimi için Grey Wolf Optimizer, dengesizlik için SMOTE kullanılmış ve aynı hastaya ait kayıtlar aynı katta tutulmuştur; bu, sızıntıyı önlemek için iyi bir uygulamadır. Random Forest ve XGBoost F1 ve doğrulukta öne çıkmış (F1 0,83 ve 0,84; doğruluk 0,88), ancak AUROC değerleri 0,63–0,64 düzeyinde kalmıştır. Bu, yeniden yatışın tahmin edilmesinin zor olduğunu ve LSTM'nin burada geleneksel yöntemlerin gerisinde kaldığını göstermektedir. Pima çalışmasında 21 yaş ve üzeri 768 kadın hasta verisi kullanılmış; Random Forest, Decision Tree, Naive Bayes ve Lojistik Regresyon karşılaştırılmıştır. Random Forest %80 doğruluk, %82 kesinlik, %88 duyarlılık ve 0,83 AUC ile en iyi sonucu vermiştir [5]. PCA analizinde glikoz ve BMI'nın birinci bileşene en büyük katkıyı yaptığı görülmüştür; bu, bir değişken önem sıralaması değildir. Örneklemin görece genç ve yalnızca kadınlardan oluşması genellenebilirliği sınırlar. Yoğun bakım çalışmasında MIMIC-III veri tabanındaki 14.222 tip 2 diyabet hastası kullanılmış; altı algoritma ile ölüm riski 3 gün, 30 gün ve 365 gün için, taburculuktan sonraki 30 gün içinde yeniden yatış ise ayrıca tahmin edilmiştir [6]. Yeniden yatış için en iyi sonuç MLP ve AdaBoost ile elde edilmiştir (AUC 0,8487, doğruluk 0,9249). Yüksek doğruluk etkileyici görünse de sonuçlar yoğun bakım hastalarına özgüdür ve tüm diyabet hastalarına doğrudan genellenemez; doğruluk, sınıf dağılımına bağlı olarak yanıltıcı olabileceği için AUC ile birlikte okunmalıdır. Projemize açısından altı çalışmanın ortak artıları şunlardır: birden fazla algoritmanın aynı veri üzerinde karşılaştırılması, SMOTE gibi dengeleme yöntemlerinin kullanımı, SHAP gibi açıklanabilirlik araçları ve modellerin bir uygulamaya dönüştürülmesi. Yeniden yatış çalışmasındaki hasta bazlı veri bölme yaklaşımı da projede benimsenmeye değerdir. Eksi yönler ise şunlardır: çalışmalar farklı veri setleri ve farklı ölçütlerle raporlandığı için sonuçlar doğrudan karşılaştırılamaz ve doğruluk oranının öne çıkarılması dengesiz veride yanıltıcı olabilir. Bu nedenle projemizde yalnızca doğruluk değil, AUC, F1 ve kesinlik–duyarlılık birlikte raporlanmalı ve sonuçlar kendi veri setimizde yeniden test edilmelidir. Bu değerlendirme, makalelerin kendi raporladığı sonuçlara dayanmaktadır; yeniden deneyler yapılmamıştır.

Kaynakça

[1] A Proposed Technique Using Machine Learning for the Prediction of Diabetes Disease through a Mobile App. International Journal of Intelligent Systems (2024). https://doi.org/10.1155/2024/6688934

[2] A Novel Machine Learning Approach for Diagnosing Diabetes with a Self-Explainable Interface. Healthcare Analytics, 5, 100301 (2024).

[3] Pediatric Diabetes Prediction Using Deep Learning. Scientific Reports, 14, 4206 (2024). https://doi.org/10.1038/s41598-024-51438-4

[4] Comparison of Machine Learning Models for Predicting 30-Day Readmission Rates for Patients with Diabetes. Journal of Medical Artificial Intelligence, 7, 23 (2024). https://doi.org/10.21037/jmai-24-70

[5] Machine Learning Algorithm-Based Prediction of Diabetes Among Female Population Using PIMA Dataset. Healthcare, 13(1), 37 (2025). https://doi.org/10.3390/healthcare13010037

[6] Machine Learning-Based Predictions of Mortality and Readmission in Type 2 Diabetes Patients in the ICU. Applied Sciences, 14(18), 8443 (2024). https://www.mdpi.com/2076-3417/14/18/8443